



Факультет компьютерных наук

ИИ360

Москва
2026

Применение машинного обучения в задаче прогнозирования погодных условий (промежуточный этап)

Студент: Кокурин Алексей Викторович

Руководители:
Ратников Федор Дмитриевич
Бугаев Егор Петрович



Постановка задачи

Разработать метод итеративного прогнозирования погоды на n шагов вперёд с использованием одношаговой модели.

Отличительное свойство модели:

- предсказание оценки неопределенности на каждом шаге прогноза
- учёт шума и накопление ошибок при итеративном применении модели

Конечной целью является построение модели, позволяющей не только получать прогнозные значения, но и сопровождать их корректной оценкой уверенности, что особенно важно для практических задач прогнозирования.



Подготовка и изучение материалов

- Изучены основы теории вероятностей и мат. статистики (по источникам [1–3]).
- FourCastNet — это модель машинного обучения для глобального прогноза погоды, разработанная NVIDIA.
- WeatherGFT — это новая модель для прогноза погоды, предложенная как гибридная система, сочетающая физику и машинное обучение.
- Были изучены ML и DL на лекциях из MO1 и курса DL (ФКН)

Источники:

[1] А. Н. Ширяев. Вероятности и случайные процессы. МЦНМО, Москва, 2019.

[2] Е. С. Вентцель. Теория вероятностей. Высшая школа, Москва, 2006.

[3] М. Х. Дойч. Введение в математическую статистику. Наука, Москва, 1984.



План работы



Базовый этап

Разработка простых авторегрессионных моделей на синтетических данных с заранее известными зависимостями.



Оценка неопределенности

Исследование накопления ошибок и неопределенности в динамике прогноза.



Многошаговое прогнозирование

Реализация моделей для долгосрочного предсказания временных рядов.



Тестирование многошаговой модели

Эксперименты на датасете Moving MNIST для проверки многошаговых предсказаний.



Переход к задаче с реальными данными



Выполненные задачи

В рамках этого этапа были выполнены следующие задачи:

1. прогноз следующего значения на случае **линейной зависимости** без шума
2. **добавление шума** к предыдущей задаче
3. прогноз следующего значения и **неопределённости** следующего шага
4. прогноз следующего значения и неопределённости следующего шага для **нелинейной зависимости** и построил нейросетевую модель
5. предсказание следующего значения x_{i+1} и его неопределённости σ_{i+1} **только по текущему значению** x_i для нелинейного случая



Задача 1: Линейная зависимость без шума

Цель: восстановить коэффициент линейной зависимости по данным без шума.

Генерация данных:


$$x_{i+1} = \alpha x_i, \text{ где } \alpha = \text{const}$$

Модель: линейная регрессия

$$x_{i+1} = wx_i + b$$

Результаты: точность данной модели получилась 100%, $\text{MSE} \approx 10^{-8}$

Вывод: модель точно восстановила истинную зависимость, ошибка обусловлена машинной точностью.



Сравнение предсказанных и истинных значений:
совпадение почти идеальное.

Задача 2: Линейная зависимость с шумом

Генерация данных (добавлен шум):

$$x_{i+1} = \alpha x_i + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

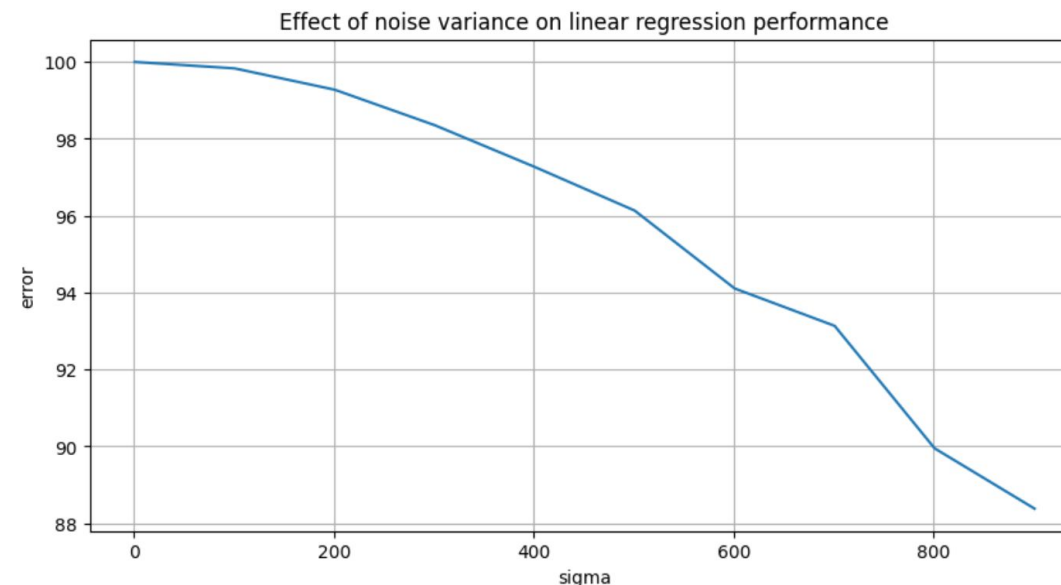
где α - коэффициент зависимости, σ - уровень шума

Модель: линейная регрессия

$$x_{i+1} = wx_i + b$$

Результат: при увеличении σ ошибка предсказания растет, а оценка w становится менее стабильной.

Вывод: при больших σ шум начинает доминировать и скрывает истинную линейную зависимость, то есть модель хуже восстанавливает параметр α .



Зависимость ошибки линейной регрессии от уровня шума σ



Задача 3: Прогноз значения и неопределенности

Цель: построить модель, которая предсказывает следующее значение и его неопределенность:

ВХОД $(x_i, \sigma_i) \rightarrow$ **ВЫХОД** (x_{i+1}, σ_{i+1})

Генерация данных: данные получены по модели с шумом

$$x_{i+1} = \alpha x_i + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_{new}^2)$$

Теоретическая неопределенность следующего шага:

$$\sigma_{i+1} = \sqrt{\alpha^2 \sigma_i^2 + \sigma_{new}^2}$$

Модель: линейная регрессия

$$X = [x_i, \sigma_i^2], \quad Y = [x_{i+1}, \sigma_{i+1}^2]$$

Результат: данные генерировались так: $\alpha \sim U(0.8, 1.1)$, $x_i \in [1, 100]$ а

$x_{i+1} = \alpha x_i + \varepsilon$, где $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ и $\sigma \sim U(0.1, 3)$. Точность модели получилась $\approx 74,4\%$.

Вывод: модель позволяет прогнозировать не только значение x_{i+1} , но и оценивать его дисперсию σ_{i+1}^2 . При многократном применении прогноза ошибка и неопределённость накапливаются.

Задача 4: Нелинейная зависимость

Генерация данных: переходим к нелинейной зависимости

$$x_{i+1} = e^{\alpha x_i} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

Модель:


MLP $2 \rightarrow 32 \rightarrow 32$ (ReLU) по входу $X = [x_i, \sigma_i]$ предсказывает \hat{x}_{i+1} и $\hat{\sigma}_{i+1}$ двумя головами (для σ используется Softplus).

Обучение: MSE по x и σ , Adam $lr = 10^{-3}$

Многошаговое авторегрессионное прогнозирование

$$(x_i, \sigma_i) \rightarrow (x_{i+1}, \sigma_{i+1})$$

Результат: при увеличении горизонта прогнозирования ошибка предсказания накапливается, а оценка неопределенности σ быстро растёт.



Прогноз x и неопределенность $\pm \sigma$ на 30 шагов вперед



Задача 5: Нелинейная зависимость — прогноз по одному x_i

Генерация данных:

$$x_{i+1} = e^{\alpha(x_i + \varepsilon_1)} + \varepsilon_2, \quad \varepsilon_1, \varepsilon_2 \sim \mathcal{N}(0, \sigma^2)$$

Модель: нейросеть (MLP 1→32→32) предсказывает среднее и неопределенность:

$$x_i \rightarrow (\hat{x}_{i+1}, \hat{\sigma}_{i+1})$$

Функция потерь: NLL для нормального распределения

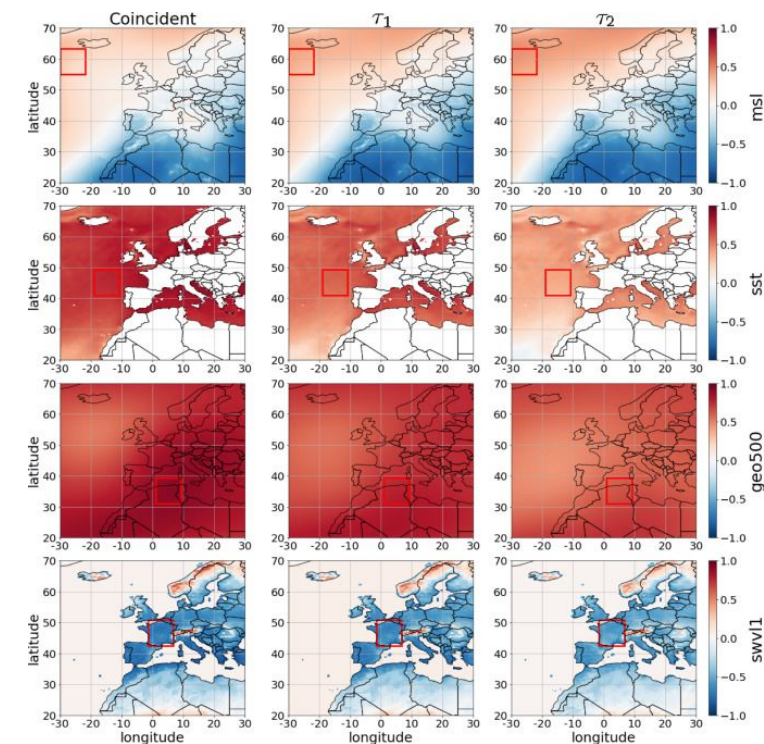

$$\mathcal{L} = \frac{(y - \hat{x})^2}{2\hat{\sigma}^2} + \ln(\hat{\sigma})$$

Результаты: модель показала хорошее качество предсказания: $\text{NLL} \approx -0.3384$

Вывод: даже используя только x_i , нейросеть способна восстанавливать x_{i+1} и адекватно оценивать неопределенность прогноза.

Продолжение работы

- Следующим этапом планируется провести эксперименты на датасете **Moving MNIST** для отработки многошагового прогнозирования и оценки неопределенности в динамике.



- Далее планируется перейти к задаче прогнозирования реальных погодных данных (температура, давление, влажность и др.) На погодных данных будет выполнено обучение модели, а также проверка качества многошагового прогноза и корректности оценки неопределенности.



Планируемые результаты

- Получить количественную оценку качества многошагового прогноза на Moving MNIST
- Проверить корректность оценки неопределенности
- Обучить и протестировать модель на реальных погодных данных (температура, давление и др.)
- Проанализировать модель, определить максимальный шаг прогнозирования, при котором модель сохраняет приемлемую точность, и момент, начиная с которого ошибка существенно возрастает.
- Подготовить итоговые графики, метрики и выводы по применимости метода



Summary

- Исследованы линейные и нелинейные зависимости с шумом на синтетических данных
- Реализованы модели для одношагового и многошагового прогнозирования с оценкой неопределенности σ
- Проанализировано накопление ошибки и рост неопределенности при увеличении горизонта прогноза
- Далее планируется тестирование многошагового прогноза на Moving MNIST
- Следующий этап — перенос подхода на реальные погодные данные и проверка качества моделей